


Métodos para Previsão de Séries Temporais

Álvaro Lemos

Sumário

1. Sobre mim
 2. Séries temporais
 3. ARIMA
 4. Suavização Exponencial
 5. Redes Feedforward
 6. Redes Recorrentes
 7. Redes LSTM
-

Oi, meu nome é Álvaro!



Sou de Salvador/BA



Formei agora em Engenharia Elétrica na UFMG

U F *m* G


Estou entrando agora no mestrado em Inteligência Computacional

U F *m* G


Sou Cientista de Dados na Bwtech




Telefonica



TIM



Personal



Sumário

1. Sobre mim
 2. Séries temporais
 3. ARIMA
 4. Suavização Exponencial
 5. Redes Feedforward
 6. Redes Recorrentes
 7. Redes LSTM
-


Um conjunto de observações indexadas
ordenadamente no tempo

Séries temporais




Vendas mensais de shampoo durante 3 anos

Séries temporais




Temperatura mínima diária em Melbourne, Austrália, entre 1981-1990

Séries temporais




Número de partos diários femininos na Califórnia em 1959


Previsão de séries temporais



Previsão de séries temporais



Previsão de séries temporais




Sumário

1. Sobre mim
 2. Séries temporais
 3. ARIMA
 4. Suavização Exponencial
 5. Redes Feedforward
 6. Redes Recorrentes
 7. Redes LSTM
-


Modelo Auto-Regressivo

Modelo Auto-Regressivo (AR)




$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}$$

Treinamento




Treinamento



$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}$$


Treinamento



$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}$$

$$J = (y_1 - \hat{y}_1)^2 + (y_2 - \hat{y}_2)^2 + \cdots + (y_N - \hat{y}_N)^2$$

Treinamento




$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}$$

$$J = (y_1 - \hat{y}_1)^2 + (y_2 - \hat{y}_2)^2 + \cdots + (y_N - \hat{y}_N)^2$$

$$\phi_1^*, \phi_2^*, \cdots, \phi_p^* = \arg \min_{\phi} J$$

Treinamento




$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}$$

$$J = (y_1 - \hat{y}_1)^2 + (y_2 - \hat{y}_2)^2 + \cdots + (y_N - \hat{y}_N)^2$$

$$\phi_1^*, \phi_2^*, \cdots, \phi_p^* = \arg \min_{\phi} J$$

Treinamento




$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}$$

$$J = (y_1 - \hat{y}_1)^2 + (y_2 - \hat{y}_2)^2 + \cdots + (y_N - \hat{y}_N)^2$$

$$\phi_1^*, \phi_2^*, \cdots, \phi_p^* = \arg \min_{\phi} J$$

Treinamento




$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}$$

$$J = (y_1 - \hat{y}_1)^2 + (y_2 - \hat{y}_2)^2 + \cdots + (y_N - \hat{y}_N)^2$$

$$\phi_1^*, \phi_2^*, \cdots, \phi_p^* = \arg \min_{\phi} J$$

Treinamento




$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}$$


$$J = (y_1 - \hat{y}_1)^2 + (y_2 - \hat{y}_2)^2 + \cdots + (y_N - \hat{y}_N)^2$$

$$\phi_1^*, \phi_2^*, \cdots, \phi_p^* = \arg \min_{\phi} J$$

Validação




Previsões



$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}$$


Previsões



$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}$$

$$\hat{y}_{t+1} = \phi_1 \hat{y}_t + \phi_2 y_{t-1} + \cdots + \phi_p y_{t-p+1}$$

Previsões




$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}$$

$$\hat{y}_{t+1} = \phi_1 \hat{y}_t + \phi_2 y_{t-1} + \cdots + \phi_p y_{t-p+1}$$

$$\hat{y}_{t+2} = \phi_1 \hat{y}_{t+1} + \phi_2 \hat{y}_t + \cdots + \phi_p y_{t-p+2}$$

Previsões




$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}$$

$$\hat{y}_{t+1} = \phi_1 \hat{y}_t + \phi_2 y_{t-1} + \cdots + \phi_p y_{t-p+1}$$

$$\hat{y}_{t+2} = \phi_1 \hat{y}_{t+1} + \phi_2 \hat{y}_t + \cdots + \phi_p y_{t-p+2}$$

Modelo Média Móvel

Modelo Média Móvel (MA - *Moving Average*)




$$\hat{y}_t = \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

$$\varepsilon_t = y_t - \hat{y}_t$$

Modelo ARMA

Modelo ARMA

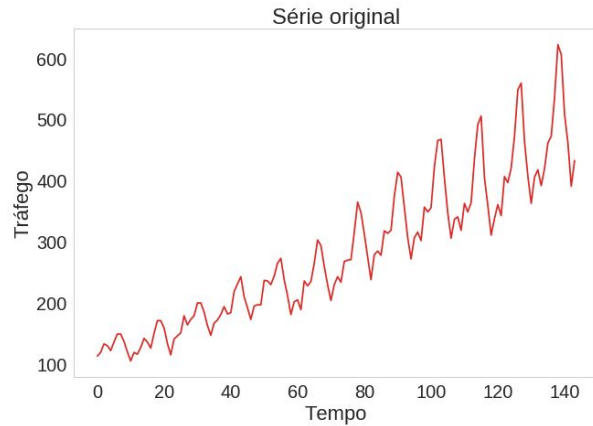


$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$


AR, MA, ARMA... Então por que AR/MA?!

*Modelos ARMA pressupõem que a série
a ser modelada é estacionária*

Séries estacionárias

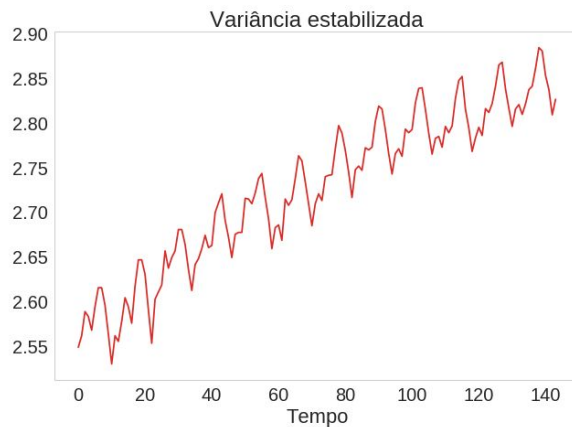



Séries estacionárias





$$y_t^{(\lambda)} = \begin{cases} \log(y_t) & \text{se } \lambda = 0 \\ (y_t^\lambda - 1)/\lambda & \text{caso contrário} \end{cases}$$

Séries estacionárias



$$y_t^{(\lambda)} = \begin{cases} \log(y_t) & \text{se } \lambda = 0 \\ (y_t^\lambda - 1)/\lambda & \text{caso contrário} \end{cases}$$

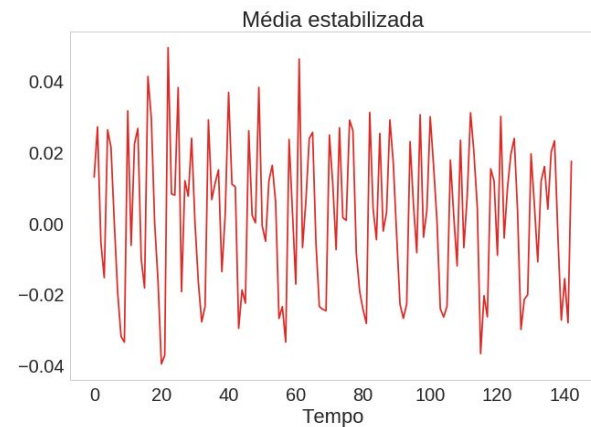

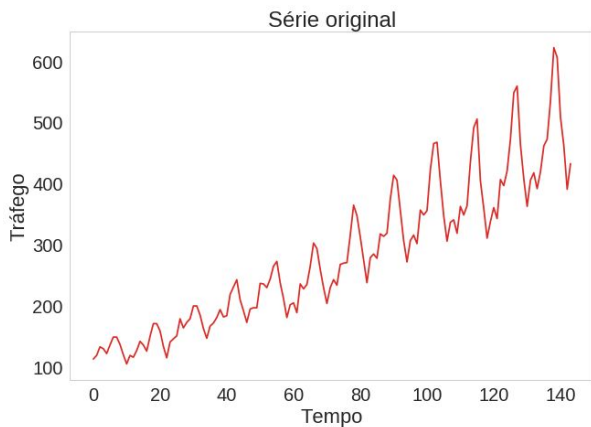
Séries estacionárias



$$y_t^{(\lambda)} = \begin{cases} \log(y_t) & \text{se } \lambda = 0 \\ (y_t^\lambda - 1)/\lambda & \text{caso contrário} \end{cases}$$

$$y'_t = y_t - y_{t-1}$$

Séries estacionárias




$$y_t^{(\lambda)} = \begin{cases} \log(y_t) \\ (y_t^\lambda - 1)/\lambda \end{cases}$$

se $\lambda = 0$


caso contrário

$$y'_t = y_t - y_{t-1}$$


ARIMA




ARIMA



ARIMA




diferencia




treina

ARMA

ARIMA




diferencia




treina

ARMA


prever



ARIMA




diferencia




treina

ARMA


prever



integra




ARIMA



diferencia


Série diferenciada



treina


ARMA

prever



integra

Série diferenciada



Sumário

1. Sobre mim
 2. Séries temporais
 3. ARIMA
 4. Suavização Exponencial
 5. Redes Feedforward
 6. Redes Recorrentes
 7. Redes LSTM
-

Suavização Exponencial Simples

$$\hat{y}_{t+1} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$

Suavização Exponencial Simples

$$\hat{y}_{t+1} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$

$$\hat{y}_{t+1} = 0.3y_t + 0.3(1 - 0.3)y_{t-1} + 0.3(1 - 0.3)^2 y_{t-2} + \cdots + 0.3(1 - 0.3)^{t-1} y_1$$


Suavização Exponencial Simples

$$\hat{y}_{t+1} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$



$$\hat{y}_{t+1} = 0.3y_t + 0.3(1 - 0.3)y_{t-1} + 0.3(1 - 0.3)^2 y_{t-2} + \cdots + 0.3(1 - 0.3)^{t-1} y_1$$

$$\hat{y}_{t+1} = 0.3y_t + 0.21y_{t-1} + 0.15y_{t-2} + \cdots$$

Suavização Exponencial Simples




Suavização Exponencial Simples



Treinamento


$$\hat{y}_{t+1} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$

Previsões



$$\hat{y}_{t+1} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$


Previsões



$$\hat{y}_{t+1} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$

$$\hat{y}_{t+2} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$

Previsões




$$\hat{y}_{t+1} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$

$$\hat{y}_{t+2} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$

$$\hat{y}_{t+3} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$

Previsões




$$\hat{y}_{t+1} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$

$$\hat{y}_{t+2} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$

$$\hat{y}_{t+3} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots + \alpha(1 - \alpha)^{t-1} y_1$$

$$\hat{y}_{t+1} = \hat{y}_{t+2} = \hat{y}_{t+3} = \cdots = \hat{y}_{t+h}$$

Suavização Exponencial com Tendência




$$\hat{y}_{t+h} = \ell_t + hb_t$$

$$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$


$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$$

Suavização Exponencial com Tendência




$$\hat{y}_{t+h} = \ell_t + hb_t$$

Suavização Exponencial com Tendência




$$\hat{y}_{t+h} = \ell_t + hb_t$$

Suavização Exponencial com Tendência




$$\hat{y}_{t+h} = \ell_t + hb_t$$

Suavização Exponencial com Tendência




$$\hat{y}_{t+h} = \ell_t + hb_t$$

Suavização Exponencial com Tendência



Método de Holt-Winters




$$\hat{y}_{t+h|t} = \ell_t + hb_t + s_{t+h-m(k+1)}$$

$$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$$

$$s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}$$


Método de Holt-Winters




Sumário

1. Sobre mim
 2. Séries temporais
 3. ARIMA
 4. Suavização Exponencial
 5. Redes Feedforward
 6. Redes Recorrentes
 7. Redes LSTM
-


Redes Neurais Feedforward




São redes onde a informação flui da entrada até a saída




São redes onde a informação flui da entrada até a saída




São redes onde a informação flui da entrada até a saída




São redes onde a informação flui da entrada até a saída



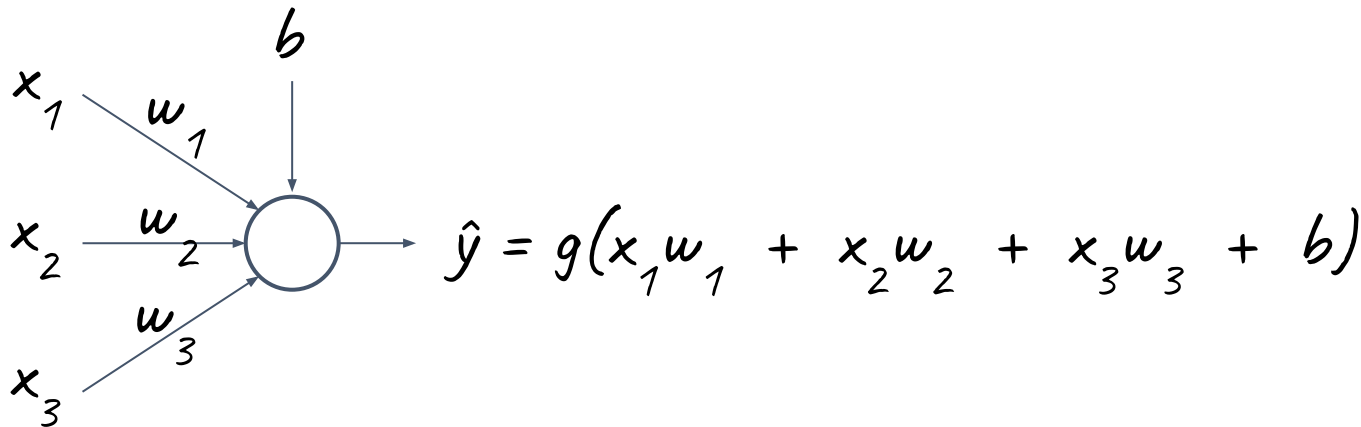
Sem fazer realimentações



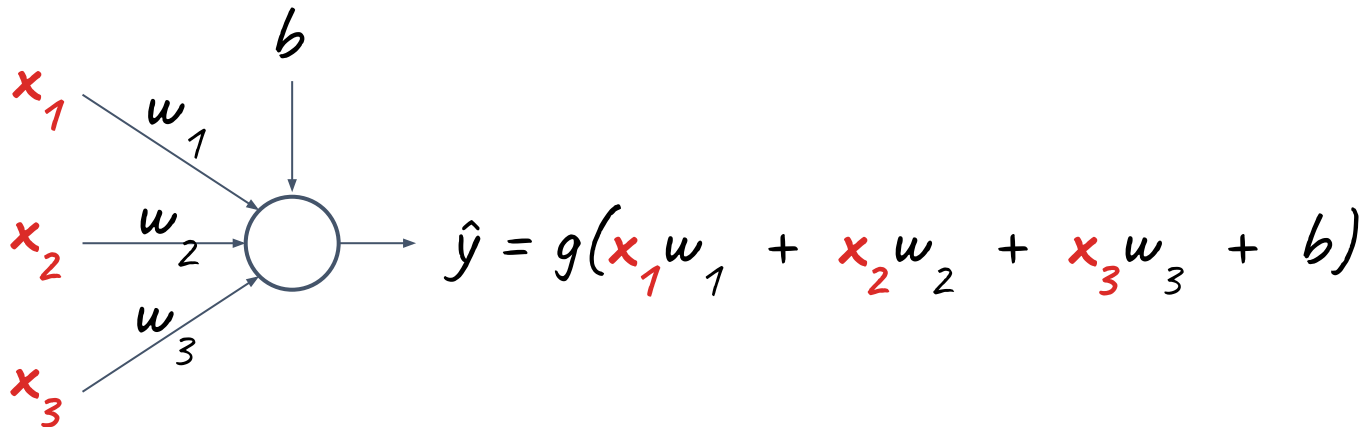
É a rede neural clássica que todo mundo conhece



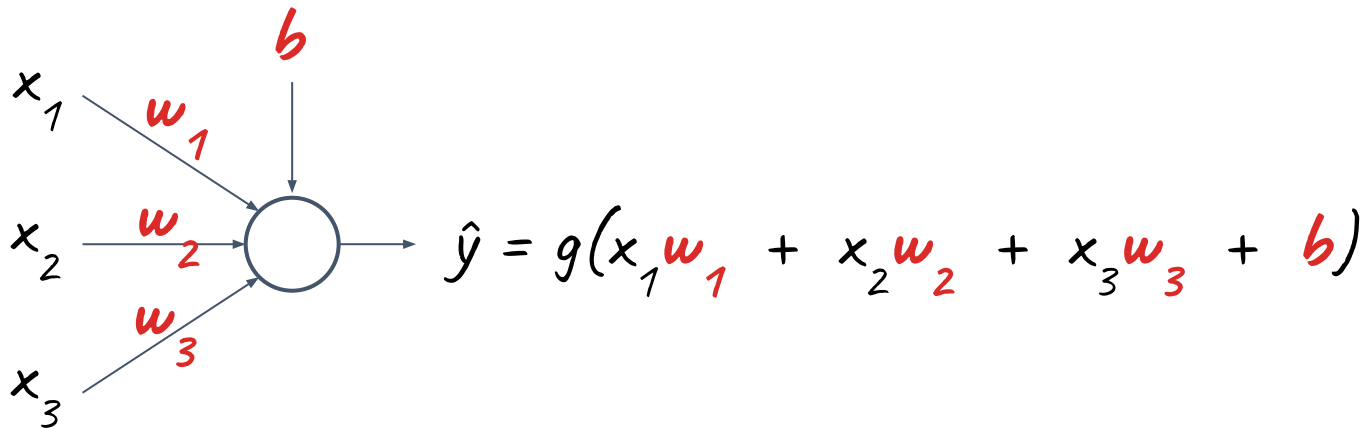
Neurônio artificial



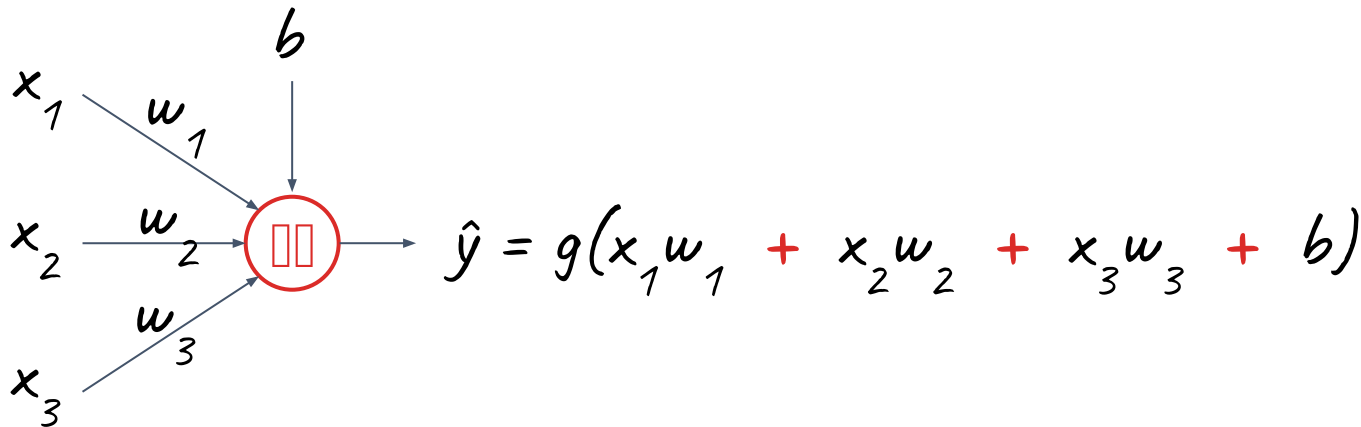
Neurônio artificial



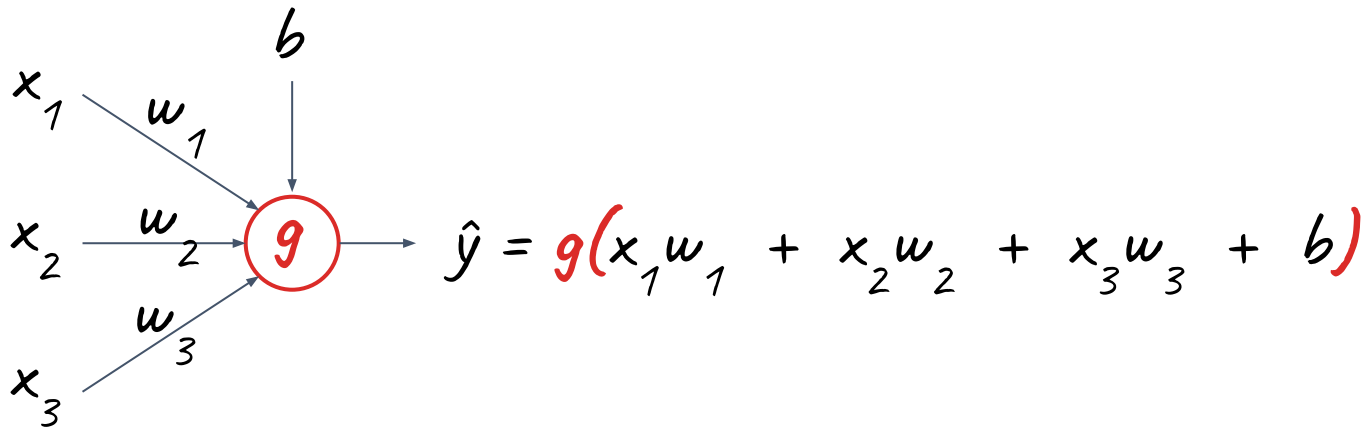
Neurônio artificial



Neurônio artificial




Neurônio artificial




Funções de ativação


Linear




Sigmoid







Tangente hiperbólica



Rectified Linear Unit (ReLU)




Funções de ativação




Funções de ativação


Linear




Sigmoid



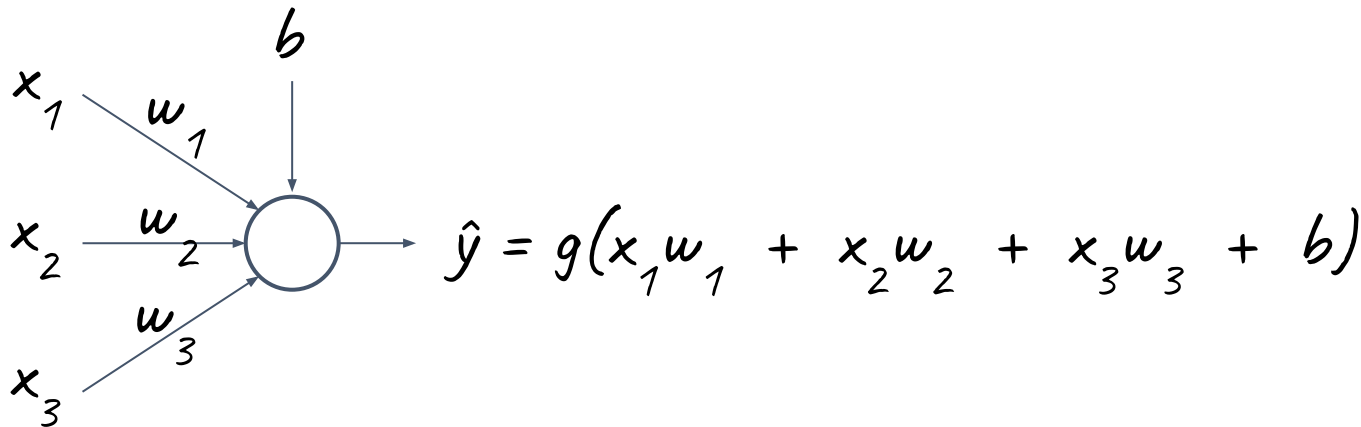
Tangente hiperbólica



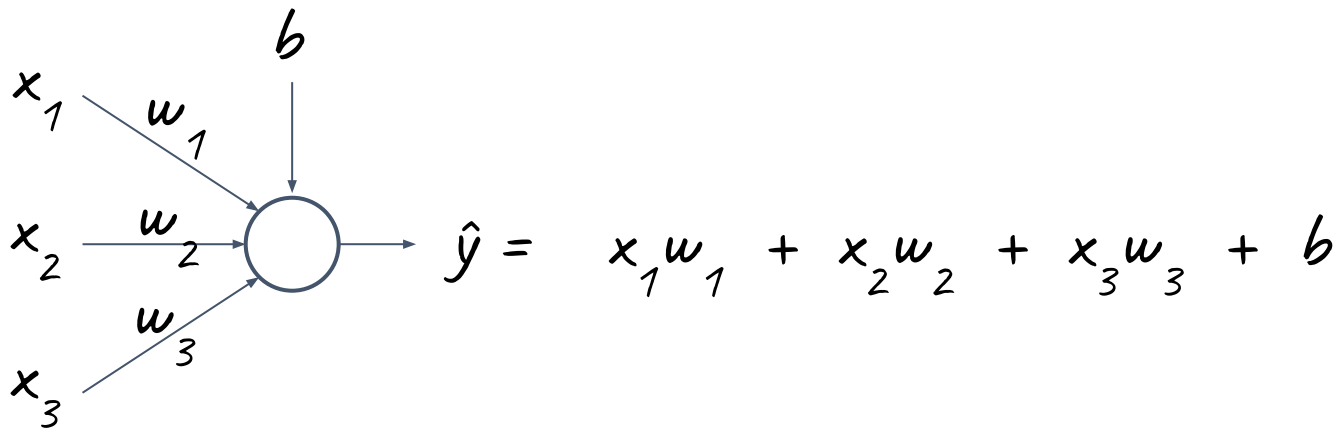
Rectified Linear Unit (ReLU)



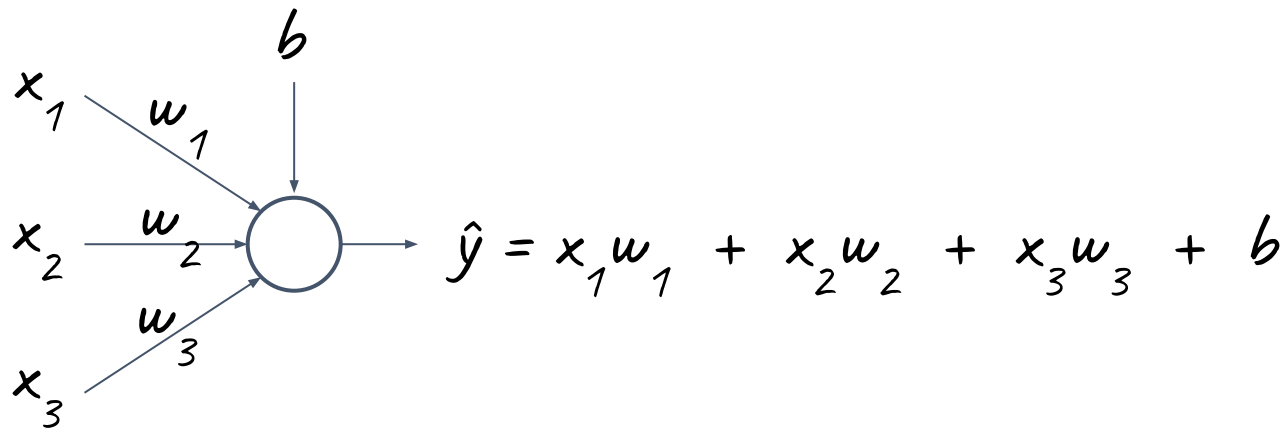
Neurônio artificial



Neurônio artificial

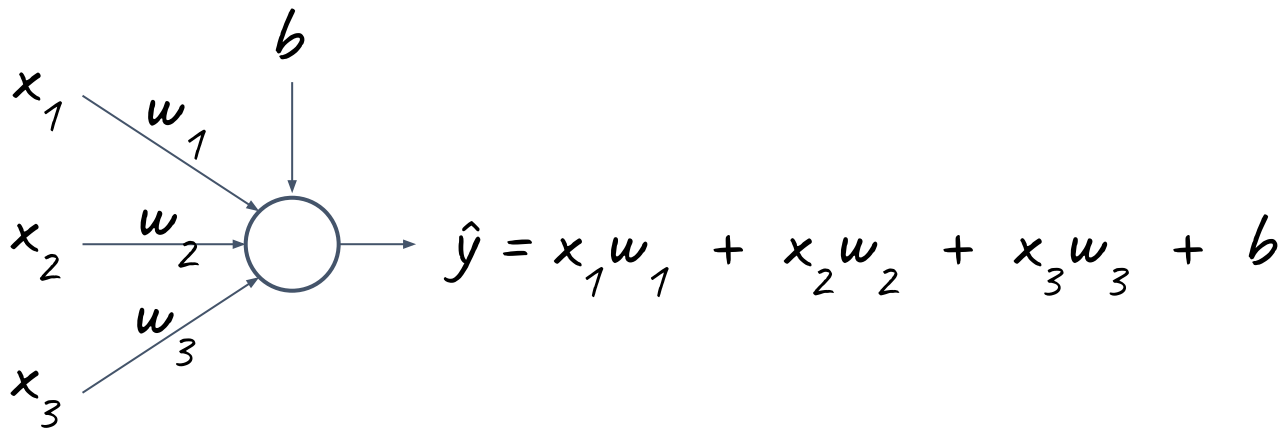


Treinamento



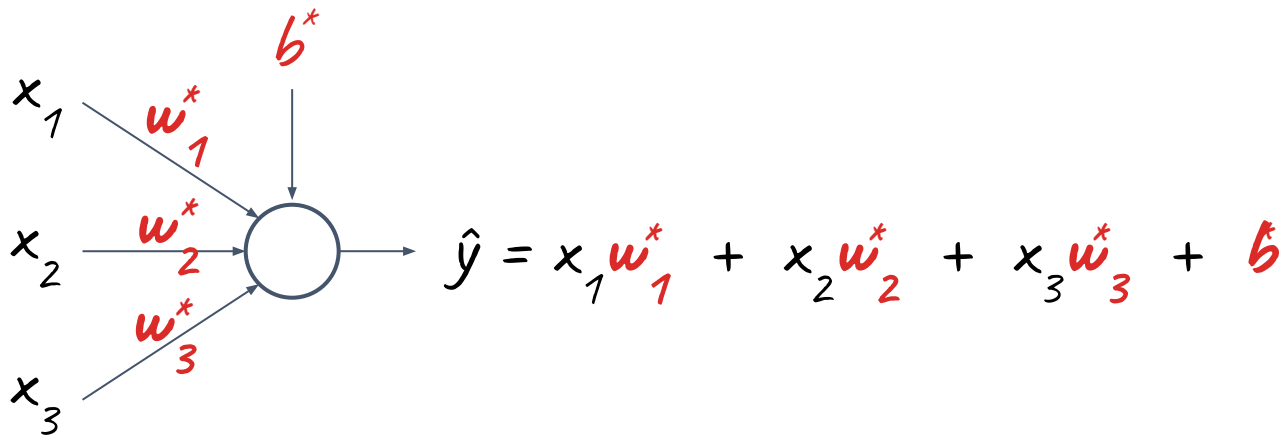
$$w_1^*, w_2^*, w_3^*, w_4^*, b^* = \arg \min_w J$$

Treinamento



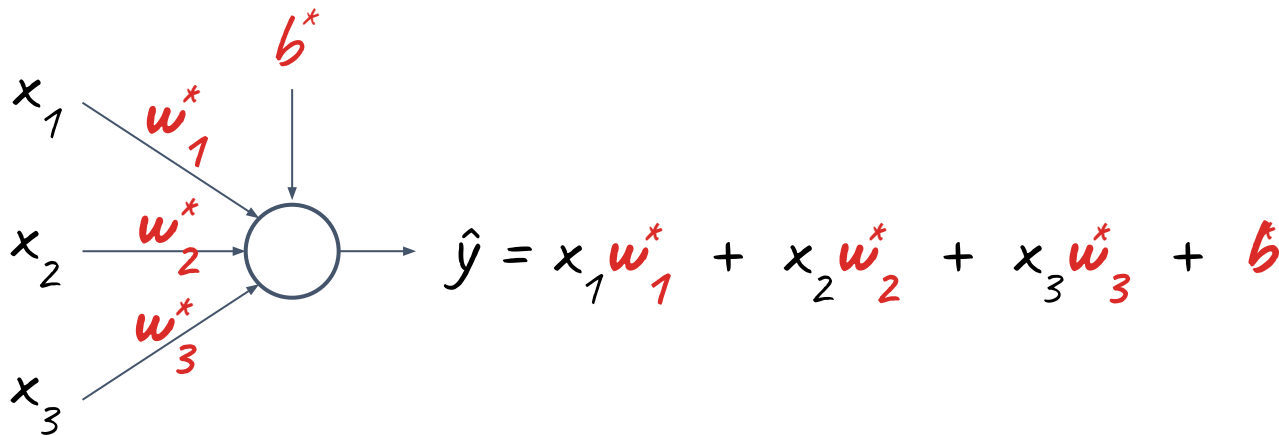
$$w_1^*, w_2^*, w_3^*, w_4^*, b^* = \arg \min_{\boxed{w}} J$$

Treinamento




$$\boxed{w_1^*}, \boxed{w_2^*}, \boxed{w_3^*}, \boxed{w_4^*}, \boxed{b^*} = \arg \min_w J$$

Treinamento




$$w_1^*, w_2^*, w_3^*, w_4^*, b^* = \boxed{\arg \min_w J}$$

Treinamento



Treinamento




Treinamento

ARIMA $\phi_1^*, \phi_2^*, \dots, \phi_p^*, \theta_1^*, \theta_2^*, \dots, \theta_q^* = \arg \min_{\phi, \theta} J$


Holt-Winters $\alpha^*, \beta^*, \gamma^* = \arg \min_{\alpha, \beta, \gamma} J$

Rede neural $w_1^*, w_2^*, w_3^*, w_4^*, b^* = \arg \min_w J$

Rearranjo do conjunto de dados




Rearranjo do conjunto de dados




Entradas			Saídas
y_1	y_2	y_3	y_4

Rearranjo do conjunto de dados




Entradas			Saídas
y_1	y_2	y_3	y_4
y_2	y_3	y_4	y_5

Rearranjo do conjunto de dados




Entradas			Saídas
y_1	y_2	y_3	y_4
y_2	y_3	y_4	y_5
y_3	y_4	y_5	y_6

Rearranjo do conjunto de dados




Entradas			Saídas
y_1	y_2	y_3	y_4
y_2	y_3	y_4	y_5
y_3	y_4	y_5	y_6
\vdots	\vdots	\vdots	\vdots

Rearranjo do conjunto de dados




Entradas			Saídas
y_1	y_2	y_3	y_4
y_2	y_3	y_4	y_5
y_3	y_4	y_5	y_6
\vdots	\vdots	\vdots	\vdots

Rearranjo do conjunto de dados




Entradas			Saídas
y_1	y_2	y_3	y_4
y_2	y_3	y_4	y_5
y_3	y_4	y_5	y_6
\vdots	\vdots	\vdots	\vdots

Rearranjo do conjunto de dados




Entradas			Saídas
y_1	y_2	y_3	y_4
y_2	y_3	y_4	y_5
y_3	y_4	y_5	y_6
\vdots	\vdots	\vdots	\vdots

Rearranjo do conjunto de dados




Entradas			Saídas
y_1	y_2	y_3	y_4
y_2	y_3	y_4	y_5
y_3	y_4	y_5	y_6
\vdots	\vdots	\vdots	\vdots

Rearranjo do conjunto de dados



Entradas			Saídas
y_1	y_2	y_3	y_4
y_2	y_3	y_4	y_5
y_3	y_4	y_5	y_6
\vdots	\vdots	\vdots	\vdots

Rearranjo do conjunto de dados




Entradas			Saídas
y_1	y_2	y_3	y_4
y_2	y_3	y_4	y_5
y_3	y_4	y_5	y_6
\vdots	\vdots	\vdots	\vdots
y_{N-3}	y_{N-2}	y_{N-1}	y_N

Esse dataset pode ser utilizado por outros modelos de regressão


- Regressão linear
- Árvore de Regressão
 - Random Forest
 - Gradient Boosting
- KNN
- SVM
- ...

Entradas			Saídas
y_1	y_2	y_3	y_4
y_2	y_3	y_4	y_5
y_3	y_4	y_5	y_6
\vdots	\vdots	\vdots	\vdots
y_{N-3}	y_{N-2}	y_{N-1}	y_N


As variáveis de entrada não precisam ser consecutivas




As variáveis de entrada não precisam ser consecutivas




Nem as janelas entre duas amostras consecutivas




Nem as janelas entre duas amostras consecutivas




Nem as janelas entre duas amostras consecutivas




Os passos podem ser maiores



Os passos podem ser maiores




Os passos podem ser maiores




E qual é a melhor configuração?


Previsões




Redes de múltiplas camadas







Redes de múltiplas camadas




Redes de múltiplas camadas




Redes de múltiplas camadas



Treinamento




$$\mathbf{w}^* = \arg \min_{\mathbf{w}} J$$



$$\mathbf{W}^{[1]*}, \mathbf{W}^{[2]*}, \dots, \mathbf{W}^{[\ell]*} = \arg \min_{\mathbf{W}} J$$

Previsões



Sumário

1. Sobre mim
 2. Séries temporais
 3. ARIMA
 4. Suavização Exponencial
 5. Redes Feedforward
 6. Redes Recorrentes
 7. Redes LSTM
-

Séries temporais são **sequências** de valores indexados no tempo


Redes feedforward encontram problemas em lidar com **dados sequenciais**

Problema #1 - Não lidam com sequências de tamanho variável

Crítica	# palavras	Positiva?
<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
<i>Deixou a desejar</i>	3	Não
<i>Melhor filme do ano com certeza</i>	6	Sim
<i>É o melhor filme que assisti</i>	6	Sim


Problema #1 - Não lidam com sequências de tamanho variável

Crítica	# palavras	Positiva?
<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
<i>Deixou a desejar</i>	3	Não
<i>Melhor filme do ano com certeza</i>	6	Sim
<i>É o melhor filme que assisti</i>	6	Sim




Problema #2 - O aprendizado dos pesos não é compartilhado em diferentes partes da rede

Crítica	# palavras	Positiva?
<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
<i>Deixou a desejar</i>	3	Não
<i>Melhor filme do ano com certeza</i>	6	Sim
<i>É o melhor filme que assisti</i>	6	Sim




Problema #2 - O aprendizado dos pesos não é compartilhado em diferentes partes da rede

	Crítica	# palavras	Positiva?
	<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
	<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
	<i>Deixou a desejar</i>	3	Não
1ª posição	Melhor filme do ano com certeza	6	Sim
3ª posição	É o melhor filme que assisti	6	Sim




Problema #2 - O aprendizado dos pesos não é compartilhado em diferentes partes da rede

	Crítica	# palavras	Positiva?
	<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
	<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
	<i>Deixou a desejar</i>	3	Não
1ª posição	Melhor filme do ano com certeza	6	Sim
3ª posição	É o melhor filme que assisti	6	Sim



Problema #2 - O aprendizado dos pesos não é compartilhado em diferentes partes da rede

	Crítica	# palavras	Positiva?
	<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
	<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
	<i>Deixou a desejar</i>	3	Não
1ª posição	Melhor filme do ano com certeza	6	Sim
3ª posição	É o melhor filme que assisti	6	Sim



Problema #3 - É difícil manter o contexto ao longo da sequência

Crítica	# palavras	Positiva?
<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
<i>Deixou a desejar</i>	3	Não
<i>Melhor filme do ano com certeza</i>	6	Sim
<i>É o melhor filme que assisti</i>	6	Sim

Problema #3 - É difícil manter o contexto ao longo da sequência


Crítica	# palavras	Positiva?
<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
<i>Deixou a desejar</i>	3	Não
<i>Melhor filme do ano com certeza</i>	6	Sim
<i>É o melhor filme que assisti</i>	6	Sim

Problema #3 - É difícil manter o contexto ao longo da sequência

Crítica	# palavras	Positiva?
<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
<i>Deixou a desejar</i>	3	Não
<i>Melhor filme do ano com certeza</i>	6	Sim
<i>É o melhor filme que assisti</i>	6	Sim



Problema #3 - É difícil manter o contexto ao longo da sequência

Crítica	# palavras	Positiva?
<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
<i>Deixou a desejar</i>	3	Não
<i>Melhor filme do ano com certeza</i>	6	Sim
<i>É o melhor filme que assisti</i>	6	Sim




As redes recorrentes lidam bem com todos esses problemas

Redes Neurais Recorrentes




Problema #2 - O aprendizado dos pesos ~~não~~ é compartilhado em diferentes partes da rede

	Crítica	# palavras	Positiva?
	<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
	<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
	<i>Deixou a desejar</i>	3	Não
1ª posição	Melhor filme do ano com certeza	6	Sim
3ª posição	É o melhor filme que assisti	6	Sim




Problema #1 - Não lidam com sequências de tamanho variável

Crítica	# palavras	Positiva?
<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
<i>Deixou a desejar</i>	3	Não
<i>Melhor filme do ano com certeza</i>	6	Sim
<i>É o melhor filme que assisti</i>	6	Sim




Problema #1 - Não lidam com sequências de tamanho variável

Crítica	# palavras	Positiva?
<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
<i>Deixou a desejar</i>	3	Não
<u><i>Melhor filme do ano com certeza</i></u>	6	Sim
<i>É o melhor filme que assisti</i>	6	Sim



Problema #3 - É difícil manter o contexto ao longo da sequência

Crítica	# palavras	Positiva?
<i>Faltou um bom roteiro, bons atores, um bom cenário e bons efeitos especiais</i>	13	Não
<i>Filme com atuação muito boa e excelente roteiro</i>	8	Sim
<i>Deixou a desejar</i>	3	Não
<i>Melhor filme do ano com certeza</i>	6	Sim
<i>É o melhor filme que assisti</i>	6	Sim



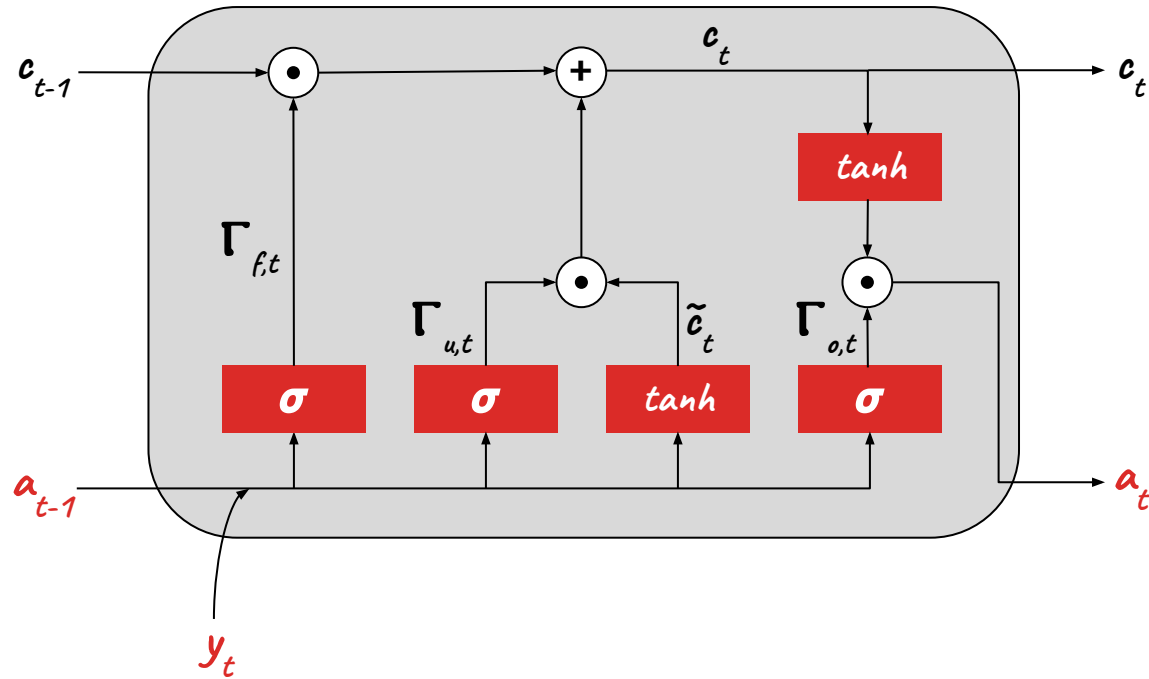
Sumário

1. Sobre mim
2. Séries temporais
3. ARIMA
4. Suavização Exponencial
5. Redes Feedforward
6. Redes Recorrentes
7. Redes LSTM

Redes Recorrentes simples têm problemas com sequências **muito** longas

Faltou um bom roteiro, bons atores, um bom cenário, bons efeitos especiais, uma boa trilha sonora, um bom diretor, bons produtores, uma boa campanha de marketing, um bom figurino e de uma boa fotografia

Redes LSTM (Long Short-Term Memory)



Perguntas???

Muito obrigado!

Álvaro Lemos



alvarolemos@gmail.com



[linkedin.com/in/alvarolemos](https://www.linkedin.com/in/alvarolemos)